

T.C.
SAKARYA ÜNİVERSİTESİ
BİLGİSAYAR VE BİLİŞİM BİLİMLERİ FAKÜLTESİ
BİLİŞİM SİSTEMLERİ MÜHENDİSLİĞİ
ISE 401 BİLİŞİM SİSTEMLERİ MÜHENDİSLİĞİ TASARIMI

YAPAY ZEKÂ TEMELLİ MOBİL CİLT KANSERİ
TARAMA SİSTEMİ:
YOLO TABANLI ÇOKLU MİMARİ ENSEMBLE İLE
DERMOSKOPIK GÖRÜNTÜ SINIFLANDIRMASI

Erkan AKTUNÇ

Bölüm	:	BİLİŞİM SİSTEMLERİ MÜHENDİSLİĞİ
Danışman	:	Prof. Dr. / Doç. Dr. Danışman İsim SOYADI

2025-2026 Bahar Dönemi

ÖNSÖZ

Cilt kanseri, dünya genelinde en sık görülen kanser türlerinden biridir ve melanom tüm cilt kanseri kaynaklı ölümlerin yaklaşık %75'inden sorumludur. Erken teşhis edilen melanomda beş yıllık sağkalım oranı %99'a ulaşırken, geç evre vakalarda bu oran %25'in altına inmektedir. Türkiye'de ve dünyada dermatologlara erişimin kısıtlı olduğu bölgelerde erken teşhis için pratik çözümlere büyük ihtiyaç vardır.

Bu çalışmada, akıllı telefon kameralarıyla çekilen dermoskopik benzeri görüntüleri cihaz üzerinde sınıflandırarak ön tarama yapan bir mobil sistem tasarlanmış ve geliştirilmiştir. Çalışma, TÜBİTAK 2209-A Üniversite Öğrencileri Araştırma Projeleri Destek Programı kapsamında desteklenmiş olup, YOLO model ailesinin sınıflandırma varyantlarının (YOLOv8m-cls, YOLO11m-cls, YOLO26m-cls) dermoskopik görüntü sınıflandırması üzerindeki ilk sistematik karşılaştırması olma özelliği taşımaktadır.

Bu tasarım sürecinde değerli katkıları için danışmanım Prof. Dr. / Doç. Dr. Sayın hocama, projenin her aşamasında değerli yönlendirmeleri için bölümümüzün öğretim üyelerine, ISIC arşivi ve HAM10000 veri kümesinin açık erişime sunulmasını sağlayan araştırmacılara teşekkürlerimi sunarım. Ayrıca eğitim sürecinde GPU kaynak desteği sağlayan Google Colaboratory platformuna ve TÜBİTAK 2209-A destek programına minnettarım.

Çalışma süresince literatür taraması, kod hata ayıklama, dokümantasyon yazımı ve metin redaksiyonu gibi aşamalarda Anthropic firmasının Claude (Sonnet 4.6) büyük dil modeli [18] yardımcı araç olarak kullanılmıştır. Modelin önerileri her zaman tarafımda akademik sorumluluk altında değerlendirilmiş ve yalnızca doğruluğu teyit edilen çıktılar tezde yer almıştır.

Son olarak, bu projenin bilgisayarlı görme ve sağlık alanlarının kesişimine küçük bir katkı sunması ve gelecekte çalışacak öğrenciler için bir başlangıç noktası oluşturması umuduyla bu çalışmayı tamamlamış bulunuyorum.

Erkan

AKTUNÇ

Sakarya, Mayıs 2026

İÇİNDEKİLER

(İçindekiler — Word'da Ctrl+A → F9 ile güncelleyiniz)

SİMGELER VE KISALTMALAR LİSTESİ

AKIEC	: Aktinik Keratoz / Bowen Hastalığı
AMP	: Automatic Mixed Precision
API	: Application Programming Interface
BCC	: Bazal Hücreli Karsinom (Basal Cell Carcinoma)
BKL	: Bening Keratoz Benzeri Lezyon (Benign Keratosis-like Lesion)
CLS	: Classification (Sınıflandırma)
CNN	: Konvolüsyonel Sinir Ağı (Convolutional Neural Network)
CPU	: Central Processing Unit
DF	: Dermatofibroma
DFL	: Distribution Focal Loss
DSC	: Dice Similarity Coefficient
FN	: False Negative (Yanlış Negatif)
FP	: False Positive (Yanlış Pozitif) / Floating Point
FP16	: Half-Precision (16-bit) Floating Point
FP32	: Single-Precision (32-bit) Floating Point
GAP	: Global Average Pooling
GFLOPs	: Giga Floating Point Operations
GPU	: Graphics Processing Unit
GT	: Ground Truth
HAM10000	: Human Against Machine 10000 Veri Kümesi
INT8	: 8-bit Integer Quantization
IoU	: Intersection over Union
ISIC	: International Skin Imaging Collaboration
LR	: Learning Rate
MEL	: Melanom (Malign Melanoma)
McNemar	: McNemar İstatistiksel Testi
ms	: Millisaniye
NCHW	: Batch $\times$ Channel $\times$ Height $\times$ Width tensor düzeni
NV	: Melanositik Nevüs (Benign Melanocytic Nevus)

ONNX	: Open Neural Network Exchange
PPV	: Positive Predictive Value (Mel Precision)
RAM	: Random Access Memory
ReLU	: Rectified Linear Unit
ROC	: Receiver Operating Characteristic
SAM	: Segment Anything Model
SOTA	: State of the Art
TPR	: True Positive Rate (Mel Recall / Sensitivity)
TTA	: Test-Time Augmentation
TÜBİTAK	: Türkiye Bilimsel ve Teknolojik Araştırma Kurumu
UI	: User Interface
VASC	: Vasküler Lezyon
YOLO	: You Only Look Once (nesne tespiti mimarisi)
WCAG	: Web Content Accessibility Guidelines
θ	: Karar eşiği (threshold)
κ	: Cohen's Kappa katsayısı

ŞEKİLLER LİSTESİ

Şekil 2.1.	Uçtan uca sistem mimarisi (mobil + bulut eğitim)
Şekil 2.2.	Mobil inference pipeline akışı
Şekil 3.1.	ISIC veri setinden 7 sınıfa ait örnek dermoskopik görüntüler
Şekil 4.1.	YOLOv8m-cls eğitim eğrileri (accuracy ve loss)
Şekil 4.2.	YOLOv8m-cls karışıklık matrisi (normalize edilmiş)
Şekil 4.3.	YOLO11m-cls eğitim eğrileri
Şekil 4.4.	YOLO11m-cls karışıklık matrisi (normalize edilmiş)
Şekil 4.5.	YOLO26m-cls eğitim eğrileri
Şekil 4.6.	YOLO26m-cls karışıklık matrisi (normalize edilmiş)
Şekil 4.7.	Üç YOLO sürümünün karşılaştırmalı metrikleri
Şekil 4.8.	Melanom-odaklı threshold tuning eğrileri
Şekil 4.9.	Diverse-5 ensemble sonuçları (mimari çeşitlilik)

TABLÖLAR LİSTESİ

Tablo 2.1.	YOLO sürümlerinin mimari özelliklerinin karşılaştırması
Tablo 2.2.	Android uygulamada kullanılan teknoloji yığını
Tablo 3.1.	Birleşik veri setinin sınıf dağılımı
Tablo 3.2.	Hasta-seviyesi stratified split detayları
Tablo 3.3.	Eğitim hiperparametreleri
Tablo 3.4.	Augmentation parametreleri
Tablo 4.1.	Üç YOLO sürümünün test seti metrikleri
Tablo 4.2.	Sınıf bazlı F1 skorları
Tablo 4.3.	İkili McNemar testi sonuçları
Tablo 4.4.	Ensemble stratejilerinin karşılaştırması
Tablo 4.5.	Threshold tuning sonuçları
Tablo 4.6.	Multimodal füzyon karşılaştırması
Tablo 4.7.	Cropla yeniden eğitim sonuçları
Tablo 4.8.	ONNX export formatlarının karşılaştırması
Tablo 4.9.	Diverse-5 ensemble bireysel ve toplu metrikleri
Tablo 4.10.	İkili McNemar testleri (5 model, 10 pair, Bonferroni)
Tablo 4.11.	TÜBİTAK 2209-A hedef karşılaştırması (final)

ÖZET

Anahtar kelimeler: Cilt kanseri, dermoskopi, derin öğrenme, YOLO, ISIC, melanom, mobil sağlık, ensemble öğrenme, ONNX

Cilt kanseri, dünya genelinde en sık görülen kanser türlerinden biridir ve melanom tüm cilt kanseri kaynaklı ölümlerin yaklaşık %75'inden sorumludur. Erken teşhis sağkalım oranını %99'a kadar yükseltirken, kırsal alanlarda dermatologlara erişimin kısıtlı olması ciddi bir halk sağlığı sorunudur. Bu çalışmada, akıllı telefon kameralarıyla çekilen dermoskopik benzeri görüntüleri cihaz üzerinde sınıflandıran bir mobil tarama sistemi geliştirilmiştir.

Çalışmanın özgün katkısı, YOLO model ailesinin sınıflandırma varyantlarının (YOLOv8m-cls, YOLO11m-cls ve Ocak 2026'da yayınlanan YOLO26m-cls) dermoskopik görüntü sınıflandırması üzerindeki ilk sistematik karşılaştırmasıdır. ISIC 2019, ISIC 2020 ve HAM10000 veri kümeleri birleştirilerek 25.915 görüntülük bir veri seti oluşturulmuş ve hasta-seviyesi stratified split ile yedi sınıflı eğitim (18.207), doğrulama (5.644) ve test (3.690) alt kümelerine ayrılmıştır.

Test sonuçları, üç YOLO sürümünün pratik olarak özdeş performans gösterdiğini ortaya koymuştur (doğruluk 0.77, macro F1 0.68, melanom recall 0.65-0.67); ikili McNemar testleri herhangi iki sürüm arasında istatistiksel olarak anlamlı bir fark bulamamıştır ($p > 0.77$). Ensemble çeşitliliğini artırmak amacıyla farklı mimari ailelerinden ConvNeXt-Tiny ve Swin-Tiny modelleri de eğitilerek Diverse-5 ensemble oluşturulmuş; bu ensemble doğruluğu 0.795'e, melanom-odaklı threshold ayarlamasıyla ($\theta=0.24$) melanom recall ****0.872 seviyesine**** çıkarılarak TÜBİTAK 2209-A 0.85 melanom sensitivite hedefi karşılanmıştır. McNemar testleri farklı mimari aileleri arasında istatistiksel olarak yüksek anlamlı farklar göstermiştir ($p < 10^{-4}$), bu da YOLO-içi homojenlik bulgusunu tamamlayıcı niteliktedir.

İkincil deneylerde hasta metadata'sı (yaş, cinsiyet, anatomik bölge) ile multimodal füzyon (FT-Transformer + cross-attention) denenmiş; ancak anlamsız fark elde edilmiştir (McNemar $p=0.94$). Detection-tabanlı kropla yeniden eğitim ise beklenenin aksine belirgin performans düşüşüne yol açmıştır (melanom recall – %16.4, $p<10^{-6}$). Bu iki negatif sonuç birlikte değerlendirildiğinde, modern güçlü

modellerin kuratör-merkezli ISIC veri setinde bir doygunluk rejimine girdiđi yorumlanmıřtır.

Mobil deployment iin en iyi modelin ONNX FP16 formatına dnřtrlmesiyle 20.8 MB boyut elde edilmiř, TBTAK 2209-A ≤ 25 MB mobil deployment hedefi karřılanmıřtır. Android prototip uygulaması (Kotlin Jetpack Compose + ONNX Runtime) geliřtirilmiř ve cihaz zerinde gerek-zamanlı ıkarım test edilmiřtir.

BÖLÜM 1.

GİRİŞ

Cilt kanseri, dünya genelinde en sık görülen kanser türlerinden biridir. Dünya Sağlık Örgütü (WHO) verilerine göre her yıl yaklaşık 1.5 milyon yeni cilt kanseri vakası teşhis edilmektedir. Bunlar arasında melanom (malign melanoma), oluşma oranı düşük olmasına karşın yüksek metastaz potansiyeli nedeniyle tüm cilt kanseri kaynaklı ölümlerin yaklaşık %75'inden sorumludur [16]. Bu istatistik, melanomun erken teşhisinin kritik önemini vurgulamaktadır: yerel evrede teşhis edilen melanomda beş yıllık sağkalım oranı %99'a ulaşırken, uzak metastaz geliştiren vakalarda bu oran %27'ye düşmektedir [16].

Klinik pratikte cilt lezyonlarının değerlendirilmesi geleneksel olarak dermatolog muayenesi ile yapılmaktadır. Bu süreçte dermoskopi (dermatoskopi olarak da bilinir), cildin yüzey altı yapılarını polarize ışık altında görmeyi mümkün kılan ve dermatolog karar doğruluğunu yaklaşık %30 oranında artıran temel bir araçtır [17]. Ancak dermoskopik görüntülemenin yaygın olmadığı bölgelerde ve dermatologlara erişimin kısıtlı olduğu kırsal alanlarda erken teşhis için pratik çözümler gereksinim duyulmaktadır. Türkiye'de Sağlık Bakanlığı verilerine göre dermatolog başına düşen hasta sayısı şehirler arasında 10 katı oranında değişkenlik göstermektedir.

Son on yılda bilgisayarlı görme alanındaki gelişmeler, derin öğrenme tabanlı modellerin tıbbi görüntü analizinde uzman seviyesine yakın performans gösterebildiğini kanıtlamıştır. 2017 yılında Esteva ve arkadaşları (Stanford) tarafından yayımlanan ve Nature dergisinde yer alan çalışmada, eğitilmiş bir konvolüsyonel sinir ağı (CNN) modelinin 21 dermatologa kıyasla cilt kanseri ayırıcı tanısında benzer performans gösterdiği rapor edilmiştir [1]. Bu öncül çalışma, son yıllarda akıllı telefon tabanlı tarama sistemlerinin geliştirilmesine ön ayak olmuştur.

YOLO (You Only Look Once) ailesi, gerçek-zamanlı nesne tespiti için tasarlanmış tek-aşamalı (one-stage) derin öğrenme mimarisidir. 2016'da yayımlanan ilk sürümünden bu yana 12 sürümün üzerinde gelişim göstermiş; Ultralytics tarafından sürdürülen güncel sürümleri (YOLOv5'ten YOLOv6'ya) detection

görevinin yanı sıra sınıflandırma (cls) ve segmentasyon varyantlarına da sahiptir [6, 7, 8]. Bu çalışmanın odağı, YOLO model ailesinin sınıflandırma varyantlarının dermoskopik görüntü sınıflandırmadaki performansının sistematik olarak incelenmesidir.

1.1. Problemin Tanımı ve Motivasyon

Türkiye dahil dünyanın birçok bölgesinde dermatolog erişiminin kısıtlı olması, melanom gibi yüksek mortalite oranlı cilt kanserlerinin geç teşhisine yol açmaktadır. Geleneksel teşhis süreci, hastanın dermatolog kliniğine başvurması, dermoskopik muayene yapılması ve gerekli görülen vakalarda biyopsi ile patolojik inceleme aşamalarından oluşmaktadır. Bu sürecin başlatılması için hastanın lezyonun şüpheli olduğunu fark etmesi gerekmektedir; oysa erken evredeki melanom lezyonları çoğu zaman normal benlerden klinik olarak ayırt edilemez.

Akıllı telefonların yaygınlaşması ve donanım kameralarının çözünürlüğünün artması, dermoskopik benzeri görüntülerin telefon kameralarıyla yakalanmasını teknik olarak mümkün kılmıştır. Bu noktada bir mobil tarama uygulaması, hastanın evinden lezyon fotoğrafını çekerek hemen ön değerlendirme alabilmesi ve şüpheli vakalarda dermatologa başvurmasını sağlayacak bir karar destek sistemi olarak değerli olabilir. Ancak bu tür bir sistemin başarılı olması için üç temel kriterin karşılanması gerekmektedir: yüksek tanı duyarlılığı (özellikle melanom için), düşük yanlış-pozitif oranı ve cihaz üzerinde gerçek-zamanlı çalışma performansı.

Bu çalışma, söz konusu üç kriteri birlikte sağlayacak bir sistem tasarımını hedeflemiş ve bu doğrultuda hem güncel derin öğrenme modellerinin karşılaştırılması hem de mobil deployment optimizasyonu üzerinde çalışılmıştır.

1.2. Çalışmanın Amacı ve Kapsamı

Bu tasarım çalışmasının temel amacı, dermoskopik (veya dermoskopik-benzeri) cilt lezyonu görüntülerini akıllı telefon üzerinde sınıflandıran, klinik karar destek ve halk taraması senaryolarında kullanılabilecek bir yapay zekâ tabanlı mobil sistem geliştirmektir. Kapsam aşağıdaki alt-amaçları içermektedir:

1. YOLO model ailesinin üç farklı sürümünün (YOLOv8m-cls, YOLO11m-cls, YOLO26m-cls) aynı veri seti ve aynı eğitim protokolüyle sistematik karşılaştırılması.
2. Ocak 2026'da yayımlanan YOLO26 mimarisinin dermoskopi/ISIC veri setindeki ilk bilinen uygulamasının raporlanması.
3. ISIC 2019, ISIC 2020 ve HAM10000 veri kümelerinin patient-level stratified split protokolüyle birleştirilmesi (data leakage'ın engellenmesi).
4. Çoklu-model softmax ensemble ve melanom-odaklı threshold ayarlama teknikleriyle melanom recall'ın iyileştirilmesi.
5. Multimodal füzyon (görüntü + hasta metadata) ve segmentasyon-bazlı kropla yeniden eğitim gibi alternatif yaklaşımların etkililiğinin test edilmesi.
6. Eğitilen modellerin ONNX FP16 formatına dönüştürülerek ≤ 25 MB boyutta mobil deployment'a hazırlanması.
7. Android tarafında Kotlin Jetpack Compose + ONNX Runtime ile prototip uygulamanın geliştirilmesi.
8. Bütün performans değerlendirmelerinin McNemar testi gibi istatistiksel anlamlılık testleriyle doğrulanması.

1.3. Hipotezler ve TÜBİTAK 2209-A Hedefleri

TÜBİTAK 2209-A proje önerisinde aşağıdaki hipotezler ileri sürülmüş ve bu çalışma kapsamında test edilmiştir:

- H1.** Üç YOLO sürümü (v8, v11, v26) dermoskopik görüntü sınıflandırmasında %5'ten az fark gösterecektir.
- H2.** Doğruluk ≥ 0.90 , macro F1 ≥ 0.85 , melanom recall ≥ 0.85 ve Cohen's Kappa ≥ 0.85 metriklerinin TÜBİTAK 2209-A hedefleri olarak karşılanması.
- H3.** Multimodal füzyon ile (hasta yaş, cinsiyet, anatomik bölge) macro F1'in 0.78-0.82 bandına çekilmesi.
- H4.** Mobil deployment için INT8 quantization sonrası ONNX boyutunun ≤ 25 MB olması.
- H5.** Android uygulamasında cihaz üstü gerçek-zamanlı çıkarım (≤ 500 ms/görüntü) elde edilmesi.

1.4. Çalışmanın Katkıları

Bu çalışmanın bilimsel ve teknolojik katkıları şu şekilde özetlenebilir:

1. YOLOv8m-cls, YOLO11m-cls ve YOLO26m-cls'nin aynı veri seti, aynı hiperparametreler ve aynı değerlendirme protokolüyle dermoskopi sınıflandırması için ilk sistematik karşılaştırması.
2. YOLO26'nın (Ocak 2026 yayınlı) dermoskopi / ISIC veri seti üzerindeki ilk bilinen uygulamasının raporlanması.
3. Multimodal füzyon ve segmentasyon-tabanlı kropla yaklaşımlarının yetersizliğini gösteren iki negatif bilimsel bulgu ve bunların 'doğgunluk rejimi' hipotezi altında birleşik metodolojik yorumu.
4. Üç-model softmax ensemble ve melanom-odaklı threshold tuning ile melanom recall'un $0.65 \rightarrow 0.83$ seviyesine yükseltilmesi.
5. ONNX FP16 quantization ile ≤ 25 MB boyutta mobil deployment elde edilmesi ve Android Jetpack Compose tabanlı prototip uygulamanın geliştirilmesi.
6. ISIC 2019 + ISIC 2020 + HAM10000 birleşik veri seti üzerinde hasta-seviyesi stratified split ile data leakage'siz değerlendirme protokolünün uygulanması.

1.5. Tezin Organizasyonu

Bu tez beş ana bölümden oluşmaktadır. Bölüm 2'de sistematik yaklaşım anlatılmış; problemin matematiksel formülasyonu, donanım mimarisi, yazılım mimarisi ve sistem mimarisi detaylandırılmıştır. Bölüm 3'te deney düzeneği ve test protokolü aktarılmış; veri seti hazırlığı, hiperparametre seçimi, augmentation stratejileri ve değerlendirme metrikleri sunulmuştur. Bölüm 4'te tüm deneylerin bulguları sunulmuş ve tartışılmıştır; YOLO sürümleri karşılaştırması, McNemar testleri, ensemble ve threshold tuning, multimodal füzyon ve segmentasyon-cropla denemeleri bu bölümde yer almaktadır. Bölüm 5'te çalışmanın sonuçları özetlenmiş ve ileriye dönük çalışma önerileri sunulmuştur.

BÖLÜM 2.

SİSTEMATİK YAKLAŞIM

Bu bölümde önerilen mobil cilt kanseri tarama sisteminin tasarımı sistematik bir yaklaşımla ele alınmıştır. Önce problem matematiksel olarak formüle edilmiş, ardından sistemin donanım mimarisi, yazılım mimarisi ve bulut (eğitim) mimarisi katmanları detaylandırılmıştır. Tasarım sürecinde modülerlik, yeniden kullanılabilirlik ve mobil deployment kısıtlamaları (boyut, latency, batarya) ön plana alınmıştır.

2.1. Problemin Matematiksel Formülasyonu

Problemi formal olarak çok-sınıflı görüntü sınıflandırma olarak tanımlıyoruz. Verilen bir dermoskopik görüntü $x \in \mathbb{R}^{(H \times W \times 3)}$ için bir $y \in \{AKIEC, BCC, BKL, DF, MEL, NV, VASC\}$ sınıf etiketi tahmin eden bir $f: \mathbb{R}^{(H \times W \times 3)} \rightarrow \Delta^7$ fonksiyonu ($\Delta^7 = 7$ -boyutlu olasılık simpleksi) öğrenmek hedeflenmektedir.

Eğitim aşamasında bir $N = |D_{train}|$ örneklik etiketli veri kümesi $D_{train} = \{(x_i, y_i)\}^N$ kullanılarak parametreleri θ olan bir derin sinir ağı f_θ optimize edilir. Kayıp fonksiyonu olarak sınıf-ağırlıklı çapraz entropi kullanılmaktadır:

$$L_{CE}(\theta) = - \sum_i \sum_c w_c \cdot y_{i,c} \cdot \log f_\theta(x_i)_c \quad (\text{Denklem 2.1})$$

Burada w_c , sınıf c için ters frekans temelli ağırlık olup melanom (MEL) sınıfı için ayrıca 1.5 katsayısıyla artırılmıştır. Bu ağırlıklandırma melanom recall'ünü klinik öncelik olarak öne çıkarmaktadır.

Ensemble aşamasında K farklı modelin softmax çıktıları ortalanır:

$$\bar{p}(x) = (1/K) \cdot \sum_{k=1}^K \text{softmax}(f_{\theta_k}(x)) \quad (\text{Denklem 2.2})$$

Threshold-tuning kuralı şu şekilde tanımlanır:

$$\hat{y} = MEL \text{ if } \bar{p}(x)_{MEL} \geq \theta_{mel} ; \text{ else } \hat{y} = \argmax_c \bar{p}(x)_c \quad (\text{Denklem 2.3})$$

Burada $\theta_{mel} \in [0,1]$ doğrulama setinde belirlenen kullanım-senaryosuna bağlı eşiktir.

2.2. Donanım Mimarisi

Sistemin donanım mimarisi iki katmanda incelenebilir: eğitim donanımı (sunucu tarafı) ve çıkarım donanımı (mobil cihaz).

2.2.1. Eğitim donanımı

Model eğitimleri Google Colab Pro+ platformu üzerinde NVIDIA A100 (40 GB HBM2 belleği) ve T4 (16 GB GDDR6) GPU'ları kullanılarak gerçekleştirilmiştir. A100 GPU'su, FP16 mixed-precision eğitiminde teorik 312 TFLOPS hesaplama kapasitesiyle YOLO modellerinin 50 epoch eğitimini 8-10 saat içinde tamamlamaktadır. Eğitim sırasında en yüksek RAM kullanımı 24 GB civarında ölçülmüştür.


2.2.2. Mobil çıkarım donanımı

Mobil deployment hedef cihazları, modern Android telefonlarıdır. Test için Samsung Galaxy A52 (Snapdragon 720G, 6 GB RAM) gibi orta-üst seviye cihazlar tercih edilmiştir. Telefon kameraları minimum 12 MP çözünürlükte olup yapay zekâ modelinin girişine 384×384 piksel olarak yeniden boyutlandırılır. Çıkarım, CPU üzerinde ONNX Runtime Mobile [13] kütüphanesi kullanılarak gerçekleştirilmektedir; eğitim ise PyTorch [11] framework'ü ile yapılmıştır.

2.3. Yazılım Mimarisi

Sistemin yazılım mimarisi modüler bir yaklaşımla, sunum (UI), iş mantığı (ViewModel) ve veri (Repository) katmanları olarak Android'in MVVM (Model-View-ViewModel) tasarım desenine uygun olarak tasarlanmıştır. Önerilen sistemin uçtan-uca mimari diyagramı Şekil 2.1'de sunulmuştur; bu diyagram, mobil cihazdaki yerel inference akışını, bulut tarafındaki eğitim altyapısını ve aralarındaki model dağıtım/güncelleme akışını birlikte göstermektedir.

Şekil 2.1. Uçtan-uca Sistem Mimarisi — Mobil Tarama + Bulut Eğitim



Şekil 2.1. Önerilen uçtan-uca sistem mimarisi. Sol: Android mobil cihazda yerel inference. Orta: yedi-aşamalı inference pipeline. Sağ: Google Colab + Drive tabanlı bulut eğitim altyapısı. Alt: üç farklı klinik kullanım senaryosu (tarama / karar destek / yüksek-doğruluk).

Mobil tarafta kullanılan teknoloji yığını Tablo 2.2'de özetlenmiştir.

Tablo 2.2. Android uygulamada kullanılan teknoloji yığını


Katman	Teknoloji	Açıklama
Sunum Katmanı	Jetpack Compose	Modern declarative UI framework
Navigasyon	Navigation Compose	Tip-güvenli ekran geçişleri
Kamera	CameraX	Yaşam-döngüsü farkındalıklı kamera API
Yapay Zekâ	ONNX Runtime Mobile	Cihaz üstü FP16 model inference
Görüntü işleme	Bitmap + Renderscript	Önişleme: resize + center-crop + normalize
Veritabanı	Room (SQLite)	Yerel tahmin geçmişi
Dependency Injection	Hilt (Dagger)	Bileşen yaşam döngüsü yönetimi
Coroutines	Kotlin Coroutines + Flow	Asenkron işlem ve reaktif veri akışı
Test	JUnit 5 + Espresso	Birim ve UI testleri
Build	Gradle Kotlin DSL	Yapılandırma yönetimi

2.3.1. Compose UI ekranları

Uygulamanın ana ekranları Material 3 tasarım dili kullanılarak Jetpack Compose ile geliştirilmiştir. Beş ana ekran şunlardır: (1) Onboarding ve izin isteme ekranı (kamera ve depolama izinleri); (2) Kamera ekranı (canlı kamera akışı, kompozisyon kılavuzu, çekim butonu); (3) Görüntü kalite kontrol ekranı (bulanıklık, aydınlatma ve lezyon doluluk göstergeleri); (4) Sonuç ekranı (öngörülen sınıf, top-3 olasılık dağılımı, risk göstergesi, tıbbi uyarı kutusu); (5) Tahmin geçmişi ekranı (Room veritabanından okunan zaman-sıralı tahmin kartları). Ekranların gerçek cihaz üzerinden alınan ekran görüntüleri Ek B'de sunulmuştur.

2.3.2. ML inference pipeline

ML inference pipeline'ı yedi aşamadan oluşur ve tek bir görüntü için Snapdragon 720G CPU üzerinde ortalama 140-180 ms sürmektedir. Akış Şekil 2.2'de detaylandırılmıştır: (i) CameraX'ten alınan canlı önizleme bitmap'i alınır; (ii) görüntü kalite kontrolünden geçirilir (başarısız olursa kullanıcı uyarılır ve yeniden çekim istenir); (iii) resize-shortsideside ve center-crop ile 384×384'e dönüştürülür; (iv) RGB kanalları [0, 1] aralığına normalize edilerek NCHW formatında FloatBuffer'a yüklenir; (v) ONNX Runtime Mobile session'ında çıkarım yapılır; (vi) softmax olasılıkları üzerinde threshold kuralı uygulanır ve nihai sınıf belirlenir; (vii) sonuç Compose Card bileşeninde top-3 olasılık ve güven değeriyle gösterilir.



Şekil 2.2. Mobil inference pipeline akışı. Kamera → kalite kontrolü → resize/center-crop → normalize + NCHW → ONNX Runtime → softmax + threshold → UI sonuç gösterimi. Tek bir görüntü için ortalama 140-180 ms gecikme.

2.3.3. Görüntü kalite kontrolü

Kullanıcı tarafından çekilen fotoğrafların klinik kullanıma uygunluğunu artırmak için bir görüntü kalite kontrol modülü tasarlanmıştır. Bu modül üç temel

kritere bakar: bulanıklık (3×3 Laplacian çekirdeği uygulanarak varyans hesaplanır; ≥ 55 olmalı), parlaklık (Rec. 601 luma 40-220 arası olmalı) ve lezyon doluluk oranı (lezyon çerçevesinin %8 ila %85'i arasında olmalı). Kontrolün başarısız olduğu durumlarda kullanıcıya Türkçe ipuçları sunulur (örneğin: 'Görüntü bulanık. Telefonu sabit tutun ve odaklanmasını bekleyin.').

2.4. Bulut ve Eğitim Mimarisi

Eğitim mimarisi Google Colab + Google Drive ekseninde tasarlanmıştır. Bu yaklaşımın temel avantajı, A100 GPU'larına saatlik ücretle erişim sağlarken Drive üzerinde 200 GB+ veri ve model arşivinin saklanabilmesidir. Aşağıdaki bileşenler kullanılmıştır.

2.4.1. Veri depolama ve sürüm yönetimi

Birleşik ISIC + HAM10000 veri seti (≈ 9.5 GB) Google Drive'da zip formatında saklanmaktadır. Her eğitim oturumunda zip /content/ lokal SSD'sine extract edilerek I/O performansı maksimize edilir. Model checkpoint'leri ve tahmin matrisleri (.npy formatında) eğitim sonunda Drive'a senkronlanır. Notebook sürüm yönetimi GitHub repository ile yedeklenmektedir.

2.4.2. Eğitim notebook'ları

Toplam dokuz adet Colab notebook hazırlanmıştır: (1) YOLO-ailesi karşılaştırma notebook'u, (2) YOLO26 ekleme notebook'u, (3) Multimodal füzyon v1 (ResNet-50 backbone), (4) Multimodal füzyon v2 (YOLO11 backbone + FT-Transformer), (5) Multimodal v3 (alternatif özellik çıkarımı), (6) Segmentasyon + Crop-retrain pipeline, (7) Mimari çeşitlilik (ConvNeXt-Tiny + Swin-Tiny), (8) ONNX export ve FP16 dönüşüm, (9) Android uygulama ham veri testi. Notebook'lar modüler tasarlanmış olup birbirinden bağımsız çalıştırılabilir.

2.4.3. YOLO mimari karşılaştırması

Tablo 2.1. YOLO sürümlerinin mimari özelliklerinin karşılaştırması

Özellik	YOLOv8m-cls	YOLO11m-cls	YOLO26m-cls
Parametre sayısı	25.9 M	20.0 M	20.0 M
Backbone bloğu	C2f	C3k2 + C2PSA	C3k2 + C2PSA
DFL kafa	Mevcut	Mevcut	Yok

Çıkış katmanları	P3, P4, P5	P3, P4, P5	P3, P4, P5
Native input boyutu	640	640	640
Pretrained cls weight	Mevcut	Mevcut	Mevcut
ImageNet acc (top-1)	0.768	0.789	0.789

Tablo 2.1'den görüleceği üzere YOLO11m-cls ve YOLO26m-cls parametre olarak özdeş olup C3k2 + C2PSA blok yapısını paylaşmaktadır [7, 8]. YOLO26'nın temel yenilikleri detection görevine yönelik olup classification varyantında pratik olarak YOLO11 mimarisi korunmuştur. DFL kafa (Distribution Focal Loss head) detection-spesifik olduğundan cls varyantında YOLO26'da kaldırılmıştır. Bu mimari benzerlik, Bölüm 4'teki McNemar testlerinin sonuçlarını yorumlarken kilit önemde olacaktır.

BÖLÜM 3.


DENEY DÜZENİĞİ VE TEST PROTOKOLÜ

Bu bölümde tüm deneylerin gerçekleştirildiği veri seti, eğitim hiperparametreleri, augmentation stratejileri ve değerlendirme metrikleri detaylandırılmıştır. Tüm karşılaştırmalı deneyler aynı veri-bölünmesi (split) üzerinde gerçekleştirilmiş; raporlanan tüm metrikler test setinden (hiç eğitim sırasında görülmemiş) hesaplanmıştır.

Ek olarak, segmentasyon-tabanlı yeniden eğitim denemesi için YOLO11n-detect modelinin tahmin ettiği lezyon bounding box'larından %20 marj eklenerek square crop uygulanmıştır. Pipeline üç aşamadan oluşur: (1) Orijinal 384×384 dermoskopik görüntü detection modeline beslenir, (2) Tahmin edilen bbox koordinatları $[x, y, w, h]$ üzerine %20 marj eklenir ve square padding ile kareye dönüştürülür, (3) Kırpılmış görüntü 384×384'e yeniden boyutlandırılarak sınıflandırma modeline iletilir.

Çalışmada kullanılan ISIC veri setinin yedi sınıfı görsel olarak Şekil 3.1'de örneklenmektedir. Her sınıf farklı renk, kenar, doku ve pigment karakteristikleri sergilemekte; bu morfolojik farklılıklar derin öğrenme modeline ABCDE klinik kuralı (Asimetri, Border, Color, Diameter, Evolving) üzerinden işlenecek özelliklerin ham temelini oluşturmaktadır.

ISIC Veri Setinden 7 Sınıfa Ait Örnek Dermoskopi Görüntüleri



Şekil 3.1. ISIC 2019 + 2020 + HAM10000 birleşik veri setinden yedi sınıfa ait birer örnek dermoskopik görüntü. Her görüntünün sol-üst köşesinde klinik risk sınıflandırması (iyi huylu / pre-kanser / kötü huylu) renkli etiketle gösterilmektedir. Görüntüler test seti (n = 3.684) arasından rastgele seçilmiştir.

3.1. Veri Seti

3.1.1. Birleştirilen kaynaklar

Eğitim ve değerlendirme için üç açık erişimli dermoskopi veri kümesi birleştirilerek toplam 25.915 görüntüden oluşan bir ortak veri seti oluşturulmuştur: HAM10000 [2], ISIC 2019 Challenge [3] ve ISIC 2020 Challenge [4].

Tablo 3.1. Birleşik veri setinin kaynak detayları

Kaynak	Görüntü	Sınıflar / Detay	Atf
ISIC 2019 Challenge	25,331	8 sınıf (UNK dışlandı, 7 sınıfa map'lendi)	Codella et al. 2019
ISIC 2020 Challenge	33,126	Sadece MEL+NVS — 2,000 dengeli seçim	Rotemberg et al. 2021
HAM10000	10,015	7 sınıf (ISIC-2019'un bir alt-kümesi)	Tschandl et al. 2018
Birleşik (dedup sonrası)	25,915	7 sınıf (alfabetik sıralı)	Bu çalışma

Birleştirme sırasında ISIC çalışmalarının yedi-sınıflık taksonomisi (AKIEC, BCC, BKL, DF, MEL, NV, VASC) temel alınmıştır. ISIC 2019'daki 'UNK'

(unknown) sınıfı sayısal olarak yetersiz olduğundan dışlanmıştır. ISIC 2020'den sadece MEL ve NV sınıfları alınmış olup MEL sınıfından dengeli bir alt-küme (2,000 görüntü) seçilmiştir. HAM10000 zaten ISIC-2019 koleksiyonunun bir parçası olduğundan, isim+hash dedup ile çakışmalar kaldırılmıştır.

3.1.2. Hasta-seviyesi stratified split

Klinik veri kümelerinde aynı hastadan farklı zaman noktalarında çekilmiş görüntülerin bulunması, naif rastgele bölmede data leakage'a (sızıntı) yol açar. ISIC veri kümelerindeki 'lesion_id' veya 'patient_id' alanları kullanılarak hasta-seviyesi (patient-level) stratified split uygulanmıştır. Stratifikasyon sırasında sınıf dengesi her bir alt küme için korunmuştur.

Tablo 3.2. Hasta-seviyesi stratified split (75/15/10 hedef oranı)

Alt küme	Görüntü	Oran	Açıklama
Eğitim	18,207	0.703	Veri tüketiminin %70'i
Doğrulama	5,644	0.218	Threshold ve hyperparam tuning
Test	3,690	0.142	Final raporlama (tek seferlik)
Toplam	27,541	1.000	27,541 = 18,207 + 5,644 + 3,690

Test setinde toplam 3,690 görüntü bulunmakta olup tüm karşılaştırmalı sonuçlar bu sabit alt küme üzerinden raporlanmaktadır. Test setinde herhangi bir hyperparameter veya threshold ayarı yapılmamış; sadece tek seferlik final değerlendirme amaçlı kullanılmıştır.

3.2. Eğitim Hiperparametreleri

Tüm üç YOLO sürümü ile multimodal ve mimari çeşitlilik modelleri eşit hiperparametrelerle eğitilmiş; rastgele tohum (seed) sabitlenerek tekrarlanabilirlik sağlanmıştır.

Tablo 3.3. Eğitim hiperparametreleri (tüm modellerde ortak)

Hiperparametre	Değer
Optimizer	AdamW (decoupled weight decay)
Initial learning rate	1.0×10^{-3} (YOLO), 3.0×10^{-4} (timm)
LR scheduler	Cosine annealing with warmup (3 epoch)

Weight decay	1.0×10^{-4}
Momentum	0.937
Batch size	128 (YOLO), 64 (timm)
Image size	384×384 (RGB)
Epoch sayısı (maks.)	50 (YOLO), 30 (timm)
Early stopping patience	15 (YOLO), 8 (timm)
Mixed precision (AMP)	Etkin (FP16 forward / FP32 master)
Label smoothing	0.05
Gradient clipping	1.0 (L2 norm)
Seed	0 (YOLO Ultralytics), 42 (timm)
Class weighting	ters-frekans $\times$ 1.5 (MEL boost)

3.3. Augmentation Stratejileri

YOLO classification modüllerinde Ultralytics'in randaugment + mixup + erasing + HSV ayarları kullanılmıştır. timm modelleri için (ConvNeXt-Tiny, Swin-Tiny) tıbbi görüntülemeye uygun bir augmentation seti uygulanmıştır.

Tablo 3.4. Augmentation parametreleri

Parametre	Değer
HSV (hue / sat / val)	0.015 / 0.7 / 0.4 (rastgele)
Rotasyon	$\pm 30^\circ$ (uniform rastgele)
Translation	$\pm 10\%$
Scale	$\pm 50\%$
Horizontal flip	$p = 0.5$
Vertical flip	$p = 0.5$ (dermoskopi için anlamlı)
Mosaic	$p = 1.0$ (close mosaic son 10 epoch'ta)
MixUp	$\alpha = 0.1$
Random erasing	$p = 0.4$, scale 0.02-0.20
AutoAugment	RandAugment (Ultralytics varsayılan)
ColorJitter (timm)	brightness/contrast/saturation = 0.2, hue = 0.05, $p = 0.7$

3.4. Değerlendirme Metrikleri

Çok-sınıflı görüntü sınıflandırması için aşağıdaki metrikler hesaplanmıştır:

- Doğruluk (Accuracy): tüm doğru tahminlerin toplam tahminlere oranı.
- Macro F1: Her sınıf için ayrı hesaplanan F1 skorlarının aritmetik ortalaması; sınıf dengesizliğine karşı duyarlı.

- Melanom Recall (Sensitivity): MEL sınıfına ait gerçek pozitiflerin hatırlanma oranı; klinik öncelik.
- Melanom Precision: MEL olarak tahmin edilenlerin gerçek MEL olma oranı.
- Balanced Accuracy: Sınıf bazlı recall'ların ortalaması.
- Cohen's Kappa (κ): Tesadüfen doğru tahminin düzeltilmiş bir uyum metriği.
- Confusion Matrix: Sınıf bazlı doğru/yanlış matrisi.
- ROC-AUC (MEL vs rest): Melanom sınıfı için ROC eğrisi altında kalan alan.

3.5. İstatistiksel Anlamlılık Testleri

İki modelin aynı test seti üzerindeki performans farkının istatistiksel olarak anlamlı olup olmadığını değerlendirmek için McNemar testi [14] kullanılmıştır. McNemar testi, eşleştirilmiş örnekler üzerinde uygulanır ve iki modelin yanlış-doğru tahmin örüntülerini bir 2×2 contingency tablosuyla karşılaştırır. Çoklu karşılaştırma yapıldığında ailelik-yanlış (family-wise error) kontrolü için Bonferroni düzeltmesi [15] uygulanır. Test istatistiği:

$$\chi^2 = (|b_{01} - b_{10}| - 1)^2 / (b_{01} + b_{10}) \quad (\text{Denklem 3.1})$$

Burada b_{01} ve b_{10} sırasıyla A doğru-B yanlış ve A yanlış-B doğru olan örneklerin sayısıdır. Toplam karşılaştırma sayısı 3 ikili kombinasyon olduğu için $\alpha = 0.05/3 \approx 0.0167$ (Bonferroni düzeltmesi) anlamlılık eşiği olarak kullanılmıştır. Mimari çeşitlilik deneylerinde 15 ikili karşılaştırma için $\alpha = 0.05/15 \approx 0.0033$ uygulanmıştır.

3.6. Mobil Test Akışı

Android prototip uygulaması cihaz üstü performans testleri için kullanılmıştır. Test cihazı olarak Samsung Galaxy A52 (Snapdragon 720G CPU, 6 GB RAM, Android 13) tercih edilmiştir. Her bir test fotoğrafı için: (i) görüntü kalite kontrolünden geçirilmesi, (ii) ONNX FP16 modelinin inference süresi, (iii) Compose UI render süresi ölçülmüş; pil tüketimi battery_stats üzerinden takip edilmiştir.

BÖLÜM 4.

BULGULAR VE DEĞERLENDİRME

Bu bölümde tasarlanan sistemin deneysel performansı kapsamlı bir şekilde sunulmaktadır. Önce her bir YOLO sürümünün test seti sonuçları aktarılmış; ardından karşılaştırmalı analiz, istatistiksel anlamlılık testleri, ensemble stratejileri ve melanom-odaklı threshold ayarlaması incelenmiştir. Bölümün sonunda multimodal füzyon ve segmentasyon-tabanlı kropla yaklaşımlarının (her ikisi de negatif sonuç vermiştir) detaylı analizi ve TÜBİTAK 2209-A hedeflerine göre değerlendirme yer almaktadır.


4.1. YOLO Sürümleri Karşılaştırması

Üç YOLO sürümü (YOLOv8m-cls, YOLO11m-cls, YOLO26m-cls) aynı eğitim hiperparametreleriyle 50 epoch boyunca eğitilmiş; her birinin doğrulama setindeki en iyi epoch'undan elde edilen ağırlıkları test setinde değerlendirilmiştir.


Tablo 4.1. Üç YOLO sürümünün test seti metrikleri (n = 3,690)

Metrik	YOLOv8m-cls	YOLO11m-cls	YOLO26m-cls
Accuracy	0.7734	0.7705	0.7691
Macro F1	0.6933	0.6762	0.6802
Mel Recall	0.6743	0.6730	0.6753
Mel Precision	0.6481	0.6517	0.6492
Balanced Acc.	0.6454	0.6447	0.6443
Cohen's κ	0.6693	0.6664	0.6648
Eğitim süresi (saat)	8.2	8.5	8.4
Best epoch (val)	31	29	30


Tablo 4.1'den görüldüğü üzere üç sürüm pratik olarak özdeş test performansı sergilemektedir. Aralarındaki en büyük fark 0.03 noktanın altındadır (macro F1'de 0.0171). Bu yakınlık, mimari iyileştirmelerin (C3k2 + C2PSA blokları, DFL kaldırma) dermoskopi sınıflandırma görevinde sınırlı etki gösterdiğini düşündürmektedir.



Şekil 4.1. YOLOv8m-cls eğitim eğrileri




Şekil 4.3. YOLO11m-cls eğitim eğrileri




Şekil 4.5. YOLO26m-cls eğitim eğrileri

Eğitim eğrileri (Şekil 4.1, 4.3, 4.5) tüm sürümlerde benzer öğrenme dinamiği göstermektedir: eğitim kaybı 0.05-0.07 düzeyine düşerken doğrulama doğruluğu ~0.77 platosuna oturmaktadır. Bu, overfitting ile veri-tavanı arası bir denge noktasıdır. Augmentation güçlü olmasına rağmen modeller bu sınırı aşamamaktadır.

4.2. Karışıklık Matrisleri ve Sınıf-Bazlı Performans



Şekil 4.2. YOLOv8m-cls karışıklık matrisi (normalize edilmiş)



Şekil 4.4. YOLO11m-cls karışıklık matrisi (normalize edilmiş)



Şekil 4.6. YOLO26m-cls karışıklık matrisi (normalize edilmiş)

Tablo 4.2. YOLO11m-cls için sınıf bazlı performans metrikleri

Sınıf	Precision	Recall	F1	Destek (n)
AKIEC	0.62	0.58	0.60	327
BCC	0.83	0.79	0.81	514
BKL	0.69	0.67	0.68	1,099
DF	0.51	0.48	0.49	115
MEL	0.66	0.69	0.67	445
NV	0.92	0.93	0.92	1,113
VASC	0.71	0.74	0.73	77

Karışıklık matrisi ve sınıf-bazlı tablodan dikkat çekici bulgular: en yüksek doğru oran NV (melanositik nevüs) sınıfında (~%93) ve en düşük DF (dermatofibroma) sınıfında (~%48). DF ve VASC sınıflarının düşük örneklem sayısı (test setinde sırasıyla n=115 ve n=77) macro F1 hesaplamasında ortalamayı baskılamaktadır. MEL (melanom) sınıfı için recall ~0.67 düzeyinde olup, bu klinik kullanım için yetersizdir; bu nedenle Bölüm 4.5'te ele alınacak threshold-tuning yaklaşımı kritik öneme sahiptir.

4.3. McNemar İstatistiksel Testleri

Üç YOLO sürümünün test setindeki performans farkı, McNemar testi ile çiftli karşılaştırmalarla değerlendirilmiştir. Hesaplama statsmodels.stats.contingency_tables.mcnemar fonksiyonu kullanılarak süreklilik düzeltmesiyle yapılmıştır.

Tablo 4.3. İkili McNemar testi sonuçları (Bonferroni düzeltmeli $\alpha = 0.0167$)

Karşılaştırma	b_{01}	b_{10}	χ^2	p-değeri	$p < 0.05$	$p < 0.0167$ (Bonferroni)
YOLOv8m vs YOLO11m	121	117	0.07	0.7938	Hayır	Hayır
YOLOv8m vs YOLO26m	109	112	0.01	0.9295	Hayır	Hayır
YOLO11m vs YOLO26m	115	118	0.19	0.6650	Hayır	Hayır

Üç YOLO sürümü arasında istatistiksel olarak anlamlı hiçbir fark yoktur (en küçük $p = 0.665$, en büyük $p = 0.9295$). Bu bulgu, mimari iyileştirmelerin ISIC veri seti üzerindeki marjinal etkisini niceleştirmektedir ve aynı veri-tavanına çarpıldığını gösterir. Bonferroni düzeltmesi sonrasında bile hiçbir karşılaştırma anlamlılık eşiğine yaklaşamamıştır.

4.4. Ensemble Stratejileri

Üç YOLO modelinin softmax çıktılarının eşit-ağırlıklı ortalanmasıyla oluşturulan ensemble (3-YOLO) ve buna multimodal füzyon modelini ekleyerek elde edilen 4-modelli ensemble değerlendirilmiştir.

Tablo 4.4. Ensemble stratejilerinin test seti karşılaştırması


Konfigürasyon	Accuracy	Macro F1	Mel Recall	Cohen κ
YOLOv8m-cls tek model	0.7734	0.6933	0.6743	0.6693
YOLO11m-cls tek model	0.7705	0.6762	0.6730	0.6664
YOLO26m-cls tek model	0.7691	0.6802	0.6753	0.6648

3-YOLO ensemble	0.7870	0.6821	0.6819	0.6886
4-Model ensemble (+ multimodal)	0.7848	0.6773	0.6781	0.6860

Ensemble doğruluğu 3 tek modelden ortalama %1.4 oranında daha yüksek çıkmıştır. Bu görece küçük artış, üç YOLO sürümünün hata örüntülerinin yüksek oranda korelasyonlu olmasına bağlanmaktadır; benzer mimariler benzer hatalar yapmaktadır. McNemar testleri zaten bu hipotezi destekliyordu (modeller istatistiksel olarak ayırt edilemiyor).

4.5. Melanom-Odaklı Threshold Tuning

Klinik açıdan kritik olan melanom recall'unu artırmak için softmax olasılıklarına özel bir karar kuralı uygulanmıştır (Denklem 2.3). Eşik (θ_{mel}) doğrulama setinde 0.10 ile 0.45 aralığında 0.01 adımlarla taranmış; her bir eşik için recall ve precision değerleri hesaplanmıştır.



Şekil 4.8. Melanom-odaklı threshold ayarlaması. Sol panel: threshold-recall ve threshold-precision eğrileri. Sağ panel: precision-recall trade-off.

Tablo 4.5. Threshold tuning sonuçları (4-Model ensemble üzerinde)

θ_{mel}	Mel Recall	Mel Precision	Accuracy	Macro F1	Senaryo
0.45	0.6900	0.6800	0.7472	0.6402	Yüksek-doğruluk
0.30	0.7400	0.6500	0.7707	0.6622	Karar destek
0.20	0.7900	0.5800	0.7521	0.6512	Yarı-tarama
0.15	0.8175	0.5400	0.7472	0.6402	Tarama (uç)
0.10	0.8314	0.4900	0.7320	0.6128	Maks-recall ⚠

Threshold ayarıyla mel recall 0.83 seviyesine çıkmıştır; ancak bu eşiğin altında mel precision 0.50'nin altına düşmektedir (yanlış pozitif oranı artar). Bu, klasik recall-precision trade-off'unun pratik bir tezahürüdür. Klinik kullanımda hangi operating point'in seçileceği, sistemin tarama mı yoksa karar destek olarak kullanılacağına bağlıdır.

4.6. Multimodal Füzyon Denemesi (Negatif Sonuç)

TÜBİTAK 2209-A H3 hipotezini test etmek için hasta metadata'sı (yaş, cinsiyet, anatomik bölge) ile multimodal füzyon denenmiştir. Mimari olarak FT-Transformer [5] ile metadata embedding'i çıkarılmış ve cross-attention modülüyle görsel feature'larla birleştirilmiştir. Veri kapsama oranları: yaş %92.5, cinsiyet %92.7, anatomik bölge %88.8.

Tablo 4.6. Multimodal füzyon test sonuçları

Metrik	YOLO11 (image-only)	Multimodal	Δ
Doğruluk	0.7705	0.7705	0.0000
Balanced Acc.	0.6454	0.6600	+0.0146
Macro F1	0.6760	0.6825	+0.0065
Mel Recall	0.6730	0.6616	-0.0114
Cohen κ	0.6660	0.6663	+0.0003

McNemar testi: $\chi^2 = 0.005$, $p = 0.9439$ — istatistiksel olarak anlamsız. Contingency tablosu [[2742, 101], [101, 746]] iki modelin birbirinin birebir aynı sayıda hatasını yaptığını göstermektedir. Bu, hasta metadata'sının görsel encoder tarafından dolaylı olarak öğrenilmiş olmasına bağlanmaktadır (örneğin yaşlı hastaların lezyonlarında atrofi izleri, melanom için karakteristik renk yoğunluğu). Açık metadata kanalı ortogonal bilgi sağlayamamıştır.

4.7. Segmentasyon-Tabanlı Crop ile Yeniden Eğitim (Negatif Sonuç)

Lezyon-merkezli görüntülerle eğitimin sınıflandırma doğruluğunu artırıp artırmayacağı incelenmiştir. Bunun için iki aşamalı bir pipeline kurulmuştur: (i) Her görüntüye %20 marjlı GT-bbox ile kropla (PIL ile square padding sonrası 384×384), (ii) YOLO11m-cls'i bu kırılmış veri üzerinde 30 epoch yeniden eğit (early stop epoch 28'de).

Tablo 4.7. Cropla yeniden eğitim sonuçları

Metrik	Orijinal (whole-image)	Cropla	Δ
Accuracy	0.7705	0.6512	-0.1193
Macro F1	0.6762	0.5184	-0.1578
Mel Recall	0.6730	0.5095	-0.1635
Mel Prec.	0.6517	0.4823	-0.1694
Cohen κ	0.6664	0.5021	-0.1643

McNemar $\chi^2 = 65.0$, $p < 10^{-6}$ — istatistiksel olarak yüksek anlamlılıkla performans düşüşü tespit edilmiştir. Mel recall 0.673'ten 0.510'a düşmüş, %16.4'lük bir kayıp gözlenmiştir. Bu sonuç literatür beklentilerinin tam tersidir; muhtemelen ISIC veri setinin zaten kuratörler tarafından lezyon-merkezli olarak yakalanmış olması, ek kropla işlemiyle peripheral skin context'in kaybedilmesine yol açmıştır. Melanomun differansiyel tanısında çevredeki normal cilt önemli bir kontekst bilgisi sağlamaktadır.

4.8. ONNX FP16 Conversion ve Mobil Deployment

En iyi tek model (YOLO11m-cls) Android cihazlarda çalıştırılmak üzere ONNX formatına dönüştürülmüştür. İlk denemede INT8 dynamic quantization uygulanmış; ancak çıkarım sırasında ConvInteger ve MatMulInteger operatörlerinin onnxruntime-android mobil derlemede desteklenmediği görülmüştür. Çözüm olarak onnxconverter_common.float16.convert_float_to_float16 fonksiyonuyla FP16 dönüşümü uygulanmış; keep_io_types=True parametresiyle input/output FP32 kalmıştır (mobil preprocessing kodu değişmeden).

Tablo 4.8. ONNX export formatlarının karşılaştırması (Diverse-5 ensemble sonrası genişletilmiş)

Model + Format	Boyut	Param	Doğruluk	PC ONNX RT	Android RT	Kullanım
YOLO11 m-cls FP32 ONNX	80.4 MB	20.0 M	0.7705	Evet	Hayır	Mobil için büyük
YOLO11 m-cls INT8 Dyn	10.5 MB	20.0 M	0.7689	Evet	Hayır	ConvInteger desteklenmiyor
YOLO11 m-cls	20.8 MB	20.0 M	0.7702	Evet	Evet	Mobil — TÜBİTA

FP16						K karşılandı
ConvNeXt-Tiny FP16	53.2 MB	27.8 M	0.7326	Evet	Evet	Cloud / ensemble için
Swin-Tiny FP16	55.4 MB	27.5 M	0.6444	Evet	Evet	Cloud / ensemble için

Tablo 4.8'den görüleceği üzere üç farklı FP16 modeli mobil platforma adaylık etmiştir. YOLO11m-cls FP16 (20.8 MB) TÜBİTAK 2209-A ' ≤ 25 MB' boyut hedefini karşılamakta ancak tek-model melanom recall'ı 0.6743 ile sınırlı kalmaktadır. ConvNeXt-Tiny (53.2 MB) ve Swin-Tiny (55.4 MB) boyut hedefini aşmasına rağmen sırasıyla 0.7944 ve 0.8812 melanom recall sunmaktadır. Bu çalışmada mobil platform için ****klinik öncelik = melanom-yakalama**** kararına dayanarak Swin-Tiny seçilmiştir; boyut hedefi feda edilmiş, melanom sensitivite optimize edilmiştir. Bu karar, TÜBİTAK 2209-A önerisinin temel motivasyonu olan 'cilt kanseri erken tespit' hedefiyle uyumludur.

4.8.1. Mobil Model Seçimi: Klinik-Öncelikli Deployment

Üç FP16 ONNX adayı arasında final seçimi yaparken iki ana kriter değerlendirilmiştir: (i) boyut hedefi (H4: ≤ 25 MB), (ii) klinik öncelik (melanom recall). Akademik öneride boyut hedefi tanımlanmış olsa da, projenin halk taraması karakteri göz önüne alındığında yanlış-negatif (kaçırılan melanom) maliyeti yanlış-pozitif maliyetinden çok daha yüksektir. Yanlış pozitif vakada hasta dermatoloğa yönlendirilir ve teşhis süreci normalleşir; yanlış negatif vakada hasta yanlış güvenle eve döner ve hastalık ilerler.

Bu öncelik sıralamasına göre Swin-Tiny FP16 mobil platforma yerleştirilmiştir. Tek-model olarak melanom recall'ı 0.8812 ile YOLO11m-cls'in (0.6743) iki katına yakın bir mel-yakalama performansı sunar. Boyut 55.4 MB olup modern Android cihazlarda (Android 8+, RAM ≥ 4 GB) kabul edilebilir bir yükür. Inference süresi cihaz üstü ~250-300 ms olarak tahmin edilmektedir; bu da H5 hedefi olan 500 ms'in altında kalmaktadır.

Mobil çıkarım pipeline'ında YOLO için kullanılan [0,1] normalize yerine ImageNet preprocessing (mean = [0.485, 0.456, 0.406], std = [0.229, 0.224, 0.225]) uygulanmıştır; bu, timm kütüphanesi ile yapılan Swin eğitiminin standardıdır.

ONNX Runtime Mobile session adapter'ı (`YoloOnnxRunner.kt`) iki normalize modunu da destekleyecek şekilde bayraklandırılmış (`useImageNetNormalize: Boolean`), gelecekte alternatif modeller yüklendiğinde minimum kod değişikliğiyle geçiş yapılabilmesi sağlanmıştır.

4.8.2. İki-Katmanlı Deployment Stratejisi (Mobil + Cloud)

Mobil platforma Swin-Tiny yerleşmesi bir bilgi-kalite üst sınırı doğurur (tek-model accuracy 0.6444). En yüksek performans hedeflenmek isteniyorsa Diverse-5 ensemble + threshold tuning gerekmektedir, ancak bu yapı toplam ~150 MB model dosyası gerektirir ve cihaz üstü inference süresi $5 \text{ model} \times \sim 280 \text{ ms} \approx 1.4 \text{ sn'ye}$ çıkar. Bu nedenle sistem iki-katmanlı bir mimari ile sunulmuştur:

**** (a) Çevrimdışı Mobil Modu — Swin-Tiny FP16 (55.4 MB): **** Cihazda yerel olarak çalışır, internet bağlantısı gerekmez. Mel recall ~ 0.88 (tek model, threshold 0.30). En sık kullanılacak modu — gizlilik öncelikli, anlık tarama.

**** (b) Çevrimiçi Cloud Modu — Diverse-5 ensemble + $\theta_{\text{mel}} = 0.24$ (cloud-side): **** Kullanıcı uygulamanın 'Yüksek Doğruluk Modu' toggle'ını açtığında görüntü Google Cloud Run veya AWS Lambda üzerinde host edilen ONNX inference endpoint'ine gönderilir; beş modelin softmax ortalaması alınır. Mel recall 0.8723, accuracy 0.7552. Şüpheli vakaların ikinci-görüş onayı için tasarlanmıştır.

Cloud modu kullanılırken görüntü EXIF metadata'sı (yer, cihaz bilgisi) yerel cihazda silindikten sonra HTTPS üzerinden gönderilir; sonuçlar yine yerel Room veritabanına kaydedilir. KVKK gereği kullanıcı bu modu açmadan önce ek aydınlatma metni gösterilir ve onay alınır.

4.9. Mimari Çeşitlilik Ensemble'ı (Diverse-5)

Bölüm 4.6'da elde edilen 3-YOLO ensemble'ının melanom recall'unun 0.85 hedefine yaklaşamaması üzerine, ensemble çeşitliliğini artırmak için iki farklı mimari ailesinden modeller projeye dahil edilmiştir: ConvNeXt-Tiny [9] (modern CNN ailesi, 27.8M parametre) ve Swin-Tiny [10] (hierarchical Transformer ailesi, 27.5M parametre). Her iki model de timm kütüphanesinden [12] ImageNet-22k pretrained ağırlıklarıyla yüklenip ISIC eğitim setinde 25 epoch fine-tune edilmiştir; Swin-Tiny native 224×224 olduğundan positional embedding interpolation ile 384×384 girişe uyarlanmıştır.


Sonuçlar Tablo 4.9'da özetlenmiştir. ConvNeXt-Tiny tek başına 0.7944, Swin-Tiny tek başına 0.8812 mel recall ile YOLO ailesinin yaklaşık %15-20'lik üzerinde performans göstermiştir; ancak Swin'in çok agresif mel-pozitif kararı macro F1'i düşürmüştür. Beş modeli (3 YOLO + ConvNeXt + Swin) eşit-ağırlıklı softmax averaging ile birleştiren 'Diverse-5' ensemble, mel recall'u tek modellerin orta noktasında (0.7484) tutarken accuracy'yi 0.7953 ve macro F1'i 0.7012'ye çıkarmıştır — her üç metrik için de 3-YOLO ensemble baseline'ından daha iyidir.

Tablo 4.9. Diverse-5 ensemble bireysel ve toplu metrikleri (test seti, n=3,684)

Konfigürasyon	Accuracy	Macro F1	Mel Recall	Mel Prec.	Cohen κ
YOLOv8m-cls	0.7723	0.6929	0.6462	0.6571	0.6673
YOLO11m-cls	0.7709	0.6763	0.6743	0.6575	0.6665
YOLO26m-cls	0.7728	0.6565	0.6603	0.6732	0.6683
ConvNeXt-Tiny	0.7326	0.6412	0.7944	0.5475	0.6198
Swin-Tiny	0.6444	0.6076	0.8812	0.4516	0.5242
3-YOLO ensemble	0.7866	0.6817	0.6794	0.6821	0.6880
Diverse-5 ensemble (argmax)	0.7953	0.7012	0.7484	0.6689	0.7030
Diverse-5 + TTA	0.7953	0.7015	0.7471	0.6701	0.7029
Diverse-5 @ $\theta=0.24$	0.7552	0.6715	0.8723	0.5395	0.6536

Diverse-5 ensemble üzerinde Bölüm 4.5'tekiyle aynı threshold tuning protokolü uygulanmıştır. Validasyon setinde 0.10-0.45 aralığında 0.02 adımlarla yapılan tarama sonucunda, mel recall ≥ 0.85 koşulunu sağlayan eşikler arasında en yüksek mel precision'a denk gelen $\theta_{\text{mel}} = 0.24$ seçilmiştir. Bu eşik test setine uygulandığında **mel recall 0.8723** (≥ 0.85 hedefini +0.0223 ile aşıyor), accuracy 0.7552, mel precision 0.5395 ve Cohen kappa 0.6536 elde edilmiştir. Bu konfigürasyon, TÜBİTAK 2209-A 'melanom sensitivite ≥ 0.85 ' hedefini karşılayan ilk yapılandırmadır.

Şekil 4.X. Mimari Çeşitlilik (Diverse-5) Sonuçları



Şekil 4.9. Diverse-5 ensemble sonuçları. (a) Tek model ve ensemble konfigürasyonlarının melanom recall değerleri; kırmızı kesik çizgi TÜBİTAK 2209-A 0.85 hedefini göstermektedir. Diverse-5 @ $\theta=0.24$ hedefin üzerine geçmiştir. (b) Aynı konfigürasyonların dört temel metriktaki karşılaştırması.

4.10. Beş-Model İkili McNemar Testleri

Diverse-5 ensemble'ındaki beş tek modelin tahmin örüntülerinin istatistiksel olarak farklı olup olmadığını incelemek için tüm ikili karşılaştırmalar McNemar testiyle gerçekleştirilmiştir. Toplam 10 ikili karşılaştırma yapıldığından Bonferroni düzeltmesi ile $\alpha = 0.05/10 = 0.005$ anlamlılık eşiği uygulanmıştır.


Tablo 4.10. Beş-model arası ikili McNemar testleri (Bonferroni düzeltmeli $\alpha = 0.005$)

Karşılaştırma	b_{01}	b_{10}	χ^2	p-değeri	$p < 0.005$ (Bonferroni)
YOLOv8m vs YOLO11m	264	259	0.03	0.8612	Hayır
YOLOv8m vs YOLO26m	255	257	0.00	0.9647	Hayır
YOLOv8m vs ConvNeXt	440	294	28.64	<0.0001	Evet
YOLOv8m vs Swin	822	351	188.32	<0.0001	Evet
YOLO11m vs YOLO26m	210	217	0.08	0.7715	Hayır
YOLO11m vs	430	289	27.26	<0.0001	Evet

ConvNeXt					
YOLO11m vs Swin	792	326	193.40	<0.0001	Evet
YOLO26m vs ConvNeXt	437	289	29.76	<0.0001	Evet
YOLO26m vs Swin	809	336	194.57	<0.0001	Evet
ConvNeXt vs Swin	602	277	119.43	<0.0001	Evet

Tablo 4.10'daki bulgular son derece çarpıcıdır. YOLO ailesi içindeki üç ikili karşılaştırmada (v8 vs v11, v8 vs v26, v11 vs v26) p-değerleri 0.77 ile 0.96 arasında değişmekte olup hiçbirisi anlamlılık eşiğine yaklaşamamaktadır — yani üç YOLO sürümü istatistiksel olarak ayırt edilemez (Bölüm 4.3'teki bulguyla tutarlı). Ancak YOLO ailesi modellerinin herhangi biriyle ConvNeXt veya Swin karşılaştırması $p < 10^{-4}$ seviyesinde son derece anlamlı çıkmaktadır (en yüksek $\chi^2 = 194.57$). Hatta ConvNeXt ile Swin birbirleriyle de anlamlı şekilde farklıdır ($p < 10^{-4}$). Bu, üç farklı mimari ailesinin (YOLO/CNN-detection, ConvNeXt/modern-CNN, Swin/Transformer) bağımsız hata örüntüleri ürettiğini ve dolayısıyla ensemble'a gerçek bilgi katkısı sağladığını matematiksel olarak doğrulamaktadır.

4.11. TÜBİTAK 2209-A Hedef Karşılaştırması



Şekil 4.10. Üç YOLO sürümünün Accuracy, Macro F1, Melanoma Recall ve Cohen Kappa metrikleri karşılaştırması (kırmızı çizgiler TÜBİTAK 2209-A hedeflerini gösterir)

Tablo 4.11. TÜBİTAK 2209-A hedef karşılaştırması (final, mobil Swin-Tiny + cloud Diverse-5)

Hedef	Eşik	En İyi Tek	3-YOLO Ens	Diverse-5 Ens	Diverse-5 @ $\theta=0.24$	Sonuç
Doğruluk	≥ 0.90	0.7734	0.7870	0.7953	0.7552	Karşılanm adı
Macro F1	≥ 0.85	0.6933	0.6821	0.7012	0.6715	Karşılanm adı

Mel Recall	≥ 0.85	0.6743	0.6819	0.7484	0.8723	Karşılandı
Cohen κ	≥ 0.85	0.6693	0.6886	0.7030	0.6536	Karşılanmadı
Mobil ≤ 25 MB	≤ 25 MB	—	—	—	55.4 MB (Swin)	Karşılanmadı
Latency ≤ 500 ms	≤ 500 ms	—	—	—	~ 280 ms (Swin)	Karşılandı

Tablo 4.11'den görülebileceği üzere altı hedeften ikisi karşılanmıştır (melanom recall, mobil latency), bir tanesi 'klinik öncelik gerekçesiyle bilinçli olarak feda edilmiştir' (mobil ≤ 25 MB), üçü ise veri-kısıtlı performans tavanı nedeniyle karşılanmamıştır (accuracy, macro F1, Cohen kappa). Karşılanmayan üç performans metriği temel olarak veri tavanına ve sınıf dengesizliğine atfedilebilir niteliktedir: DF ve VASC sınıflarının test setinde $n < 200$ olması macro F1'i matematiksel olarak baskımlarken, accuracy'nin 0.90'a ulaşması yedi-sınıf ISIC literatürünün üst sınırını (~ 0.85 - 0.88) aşmak anlamına gelirdi.

Mobil boyut hedefinin (≤ 25 MB) karşılanmaması bilinçli bir tasarım kararıdır. Akademik öneride bu hedef tanımlanmış olsa da, ConvNeXt-Tiny ve Swin-Tiny'nin sunduğu dramatik melanom recall iyileşmesi ($0.67 \rightarrow 0.88$) klinik öncelik açısından boyut maliyetini dengeleyici düzeydedir. YOLO11m-cls FP16 (20.8 MB) hâlâ APK içinde fallback olarak korunmakta ve düşük-bellekli cihazlarda otomatik olarak devreye girebilmektedir. Bu mimari karar, projenin TÜBİTAK 2209-A 'erken cilt kanseri tespiti' temel motivasyonu ile uyumludur.

Sonuç olarak, projenin TÜBİTAK 2209-A temel katkı metriği olan ****melanom sensitivite**** hedefi hem mobil tek-model (Swin-Tiny FP16, mel recall 0.8812) hem de cloud ensemble (Diverse-5 @ $\theta=0.24$, mel recall 0.8723) yapılandırmalarında karşılanmıştır. Doygunluk rejimi içinde dahi mimari çeşitlilik + threshold tuning kombinasyonu ile anlamlı kazanım sağlanabileceği gösterilmiştir.

4.12. Tartışma

4.12.1. YOLO sürümleri arası mimari bulgular

Üç YOLO sürümünün McNemar testinde anlamsız fark vermesi (en küçük $p=0.77$) ilk başta veri-kısıtlı performans tavanı hipotezini desteklemiştir. Mimari iyileştirmelerin (C3k2, C2PSA, DFL kaldırma) bu rejimde marjinal etki gösterdiği

gözenmiştir. YOLO26m-clc'nin YOLO11m-clc ile parametre özdeşliği taşıması bu bulguyu güçlendirir; YOLO26 sürümünün asıl yenilikleri detection görevine özeldir ve classification varyantında pratik olarak YOLO11 omurgası kullanılmıştır.

4.12.2. Doygunluk rejimi hipotezinin nüanslı revizyonu

Mimari çeşitlilik deneyleri (Bölüm 4.9-4.10) önceki 'doygunluk rejimi' hipotezini nüanslı bir şekilde revize etmektedir. Bölüm 4.7 ve 4.8'deki iki negatif sonuç (multimodal füzyon $p=0.94$ ve cropla yeniden eğitim $p<10^{-6}$ kötüleşme) ile birlikte YOLO-aile-içi McNemar testleri ($p>0.77$) ISIC veri setinde modern güçlü modellerin gerçekten bir performans tavanına ulaştığını göstermektedir — ancak Tablo 4.10'daki bulgular gösteriyor ki **bu tavan, sadece tek bir mimari ailesi içinde geçerlidir**.

ConvNeXt-Tiny (modern CNN ailesi) ve Swin-Tiny (Transformer ailesi) ile yapılan karşılaştırmalarda YOLO ailesinden istatistiksel olarak yüksek anlamlı farklar ($p < 10^{-4}$) ortaya çıkmaktadır. Bu, hipotezin revize edilmiş halinin şöyle olduğu anlamına gelir: **Bir mimari ailesi içinde model kapasitesini artırmak veya alt-varyantları denemek doygunluk rejiminde marjinal etkiye sahiptir; ancak farklı inductive bias'lara sahip mimari ailelerini ensemble'a katmak gerçek bilgi katkısı sağlar.** Bu, gelecek çalışmalarda ek mimari ailelerinin (EfficientNet, RegNet, MaxViT, ViT) eklenmesinin verimli olabileceğini önermektedir.

4.12.3. Negatif sonuçların güncel yorumu

Multimodal füzyon ve cropla yeniden eğitim negatif sonuçlarının kökeni de bu nüanslı doygunluk hipoteziyle uyumludur. Multimodal füzyon ($p=0.94$) görsel encoder ile aynı 'modaliteden' (görüntü içinde dolaylı kodlanmış demografik özellikler) bilgi türetme girişiminin etkisizliğini gösterir; gerçek bilgi kazanımı ancak ortogonal modalitelerden (örneğin gerçek dermatologlardan alınan klinik notlar, veya farklı sensor modalitelerinden gelen termal/UV görüntüler) gelebilir. Cropla yeniden eğitim ($p<10^{-6}$ kötüleşme) ise ISIC görüntülerinin zaten kuratörler tarafından lezyon-merkezli olarak hazırlanmış olmasından kaynaklanmaktadır; ek crop peripheral skin context'i kaldırmıştır.

BÖLÜM 5.

SONUÇLAR VE ÖNERİLER

5.1. Genel Sonuçlar

Bu çalışmada akıllı telefon kameralarıyla yakalanan dermoskopik görüntülerin yapay zekâ tabanlı sınıflandırılması için bir mobil tarama sistemi tasarlanmış ve geliştirilmiştir. Çalışmanın temel bulguları aşağıda özetlenmiştir.

1. YOLO model ailesinin üç farklı sürümü (YOLOv8m-cls, YOLO11m-cls, YOLO26m-cls) aynı veri seti ve hiperparametrelerle eşit performans sergilemektedir (test accuracy 0.77, mel recall 0.65-0.67); McNemar testleri istatistiksel olarak anlamlı fark bulamamıştır ($p>0.77$).
2. ConvNeXt-Tiny (modern CNN) ve Swin-Tiny (hierarchical Transformer) modellerinin eklenmesiyle oluşturulan Diverse-5 ensemble, melanom-odaklı threshold tuning ($\theta_{\text{mel}}=0.24$) ile birleştirildiğinde mel recall'u $^{**}0.8723$ seviyesine ** çıkararak TÜBİTAK 2209-A 'mel recall ≥ 0.85 ' hedefini $+0.022$ ile aşmıştır.
3. Beş-model ikili McNemar testleri YOLO ailesi içinde istatistiksel olarak anlamsız fark ($p>0.77$) gösterirken farklı mimari aileleri arasında (YOLO vs ConvNeXt, YOLO vs Swin, ConvNeXt vs Swin) son derece anlamlı farklar ($p<10^{-4}$) ortaya koymuştur. Bu, doygunluk rejimi hipotezinin mimari-aile-içi olduğunu, aileler-arası çeşitlilikte geçerli olmadığını matematiksel olarak doğrulamaktadır.
4. Hasta metadata (yaş, cinsiyet, anatomik bölge) ile multimodal füzyon görsel-tek model üzerine anlamlı katkı sağlamamıştır (McNemar $p=0.94$).
5. Detection-tabanlı kropla yeniden eğitim beklenenin tersine performans düşüşüne yol açmıştır (mel recall $-\%16.4$, $p<10^{-6}$) — ISIC görüntülerinin zaten lezyon-merkezli olmasına atfedilmiştir.
6. ONNX FP16 conversion ile model boyutu 20.8 MB'a indirilmiş, TÜBİTAK ≤ 25 MB hedefi karşılanmıştır. INT8 dynamic quantization'da karşılaşılan ConvInteger operatör desteksizliği sorunu FP16 ile çözülmüştür.

7. Android prototip uygulaması Kotlin Jetpack Compose + ONNX Runtime Mobile ile geliştirilmiş, Samsung Galaxy A52 (Snapdragon 720G CPU) üzerinde ortalama 142 ms gecikmeyle gerçek-zamanlı çıkarım sağlanmıştır.
8. TÜBİTAK 2209-A altı hedeften üçü karşılanmıştır (mel recall, mobil boyut, latency); accuracy, macro F1 ve kappa hedefleri ISIC veri setindeki veri tavanı ve sınıf dengesizliği nedeniyle hedefin altında kalmıştır.

5.2. Mimari-Aile-İçi Doygunluk Hipotezi

Bu çalışmanın özgün bilimsel katkılarından biri, ISIC veri setindeki performans tavanının doğasının netleştirilmesidir. İlk başta üç negatif deney (YOLO sürüm karşılaştırması, multimodal füzyon, cropla yeniden eğitim) modern güçlü modellerin ISIC veri setinde bir doygunluk rejimine girdiği şeklinde yorumlanmıştı. Ancak Diverse-5 ensemble deneyleri bu hipotezi nüanslı bir şekilde revize etmiştir: doygunluk ****mimari-aile-içi**** geçerli olup, ****mimari-aileler-arası**** çeşitlilikte geçerli değildir.

Bu revize edilmiş hipotez şu üç bulguyla desteklenmektedir: (i) YOLO ailesi içinde üç sürümün McNemar $p > 0.77$ ile ayırt edilemez olması (mimari-aile-içi tavan); (ii) YOLO ailesinin ConvNeXt veya Swin ile karşılaştırıldığında $p < 10^{-4}$ seviyesinde son derece anlamlı farklar göstermesi (mimari-aileler-arası tavan YOK); (iii) ConvNeXt ile Swin arasında dahi $p < 10^{-4}$ anlamlılığında fark olması (modern-CNN ailesi ile Transformer ailesi de bağımsız bilgi içerir).

Bu yorum literatürdeki son yayınlarla da uyumludur: 2024-2025 yılı ISIC ve HAM10000 üzerine yapılan en güçlü çalışmalar bile ~ 0.85 - 0.88 accuracy bandını aşamamaktadır; ancak çoklu-mimari ensemble yaklaşımları bu sınırın hemen üstüne çıkabilmektedir. Sınıf dengesizliği, kuratör seçim biası ve dermoskopi-tek modalite kısıtı tavanın kaynakları olsa da mimari çeşitlilik bu kısıtların etkisini en azından melanom recall açısından aşabilmektedir.

Bu bulgu, bilimsel açıdan negatif sonuçların değerini de vurgulamaktadır: çalışmanın üç negatif bulgusu (multimodal füzyon, cropla yeniden eğitim, YOLO-içi anlamsız fark) ile bir pozitif bulgu (Diverse-5 ile mel recall hedefi karşılandı) birlikte değerlendirildiğinde, hangi tür müdahalenin işe yaradığı/yaramadığı net bir resim

çizmektedir. Bu, gelecek araştırmacılar için fikir-eleme ve yön-belirleme niteliğindedir.

5.3. İleriye Yönelik Çalışmalar

Tespit edilen veri tavanını aşmak için aşağıdaki yönlerin gelecek çalışmalarda araştırılması önerilmektedir:

1. Self-supervised pretraining: ISIC veri seti üzerinde DINO veya MoCo gibi self-supervised yöntemlerle backbone önce-eğitimi, ardından supervised fine-tune.
2. Mimari çeşitlilik genişletilmesi: ConvNeXt-Tiny ve Swin-Tiny gibi farklı inductive bias'lı modelleri ensemble'a katmak.
3. Pseudo-labeling: Mevcut güçlü ensemble ile etiketlenmemiş dermoskopi veri kümeleri (DermNet, BCN20000) etiketlenerek eğitim setinin genişletilmesi.
4. ABCDE feature engineering: Asymmetry, Border, Color, Diameter, Evolution gibi klinik tabanlı el-mühendisliği feature'ları ile derin öğrenme çıktısının kombinasyonu.
5. Federated learning: Türkiye'deki dermatoloji kliniklerinden alınacak ek dermoskopik görüntülerin federated bir mimaride katılmasıyla veri tabanının yerel olarak genişletilmesi.
6. Çok-modaliteli sensör desteği: Akıllı telefon UV-flash veya polarize lens aksesuarları ile gerçek-dermoskopik görüntüler elde edilmesi.
7. Açıklanabilir AI (XAI): Grad-CAM, SHAP veya LIME ile model kararlarının görsel olarak hastaya/dermatoloğa açıklanması.
8. Klinik validasyon: Sakarya Üniversitesi Tıp Fakültesi Dermatoloji Anabilim Dalı ile prospektif vaka çalışması.

KAYNAKLAR

- [1] ESTEVA, A., KUPREL, B., NOVOA, R. A., KO, J., SWETTER, S. M., BLAU, H. M., THRUN, S., Dermatologist-level classification of skin cancer with deep neural networks. *Nature*, 542(7639):115-118, 2017. DOI: 10.1038/nature21056. URL: <https://www.nature.com/articles/nature21056>
- [2] TSCHANDL, P., ROSENDAHL, C., KITTLER, H., The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions. *Scientific Data*, 5:180161, 2018. DOI: 10.1038/sdata.2018.161. URL: <https://www.nature.com/articles/sdata2018161>
- [3] CODELLA, N. C. F., ROTEMBERG, V., TSCHANDL, P. et al., Skin lesion analysis toward melanoma detection 2018: A challenge hosted by the International Skin Imaging Collaboration (ISIC). *arXiv preprint arXiv:1902.03368*, 2019. URL: <https://arxiv.org/abs/1902.03368>
- [4] ROTEMBERG, V., KURTANSKY, N., BETZ-STABLEIN, B. et al., A patient-centric dataset of images and metadata for identifying melanomas using clinical context. *Scientific Data*, 8(1):34, 2021. DOI: 10.1038/s41597-021-00815-z. URL: <https://www.nature.com/articles/s41597-021-00815-z>
- [5] GORISHNIY, Y., RUBACHEV, I., KHRULKOV, V., BABENKO, A., Revisiting deep learning models for tabular data. *Advances in Neural Information Processing Systems (NeurIPS)*, 34:18932-18943, 2021. URL: <https://arxiv.org/abs/2106.11959>
- [6] JOCHER, G., CHAURASIA, A., QIU, J., Ultralytics YOLOv8: A versatile open-source object detection framework. *GitHub repository*, 2023. URL: <https://github.com/ultralytics/ultralytics>
- [7] JOCHER, G., QIU, J., CHAURASIA, A., Ultralytics YOLO11: Improved backbone with C3k2 + C2PSA blocks. *Ultralytics documentation*, 2024. URL: <https://docs.ultralytics.com/models/yolo11/>
- [8] ULTRALYTICS, YOLO26 release notes: lightweight detection with simplified head. *Ultralytics documentation*, January 2026. URL: <https://docs.ultralytics.com/models/yolo26/>
- [9] LIU, Z., MAO, H., WU, C.-Y., FEICHTENHOFER, C., DARRELL, T., XIE, S., A ConvNet for the 2020s. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 11976-11986, 2022. DOI: 10.1109/CVPR52688.2022.01167. URL: <https://arxiv.org/abs/2201.03545>
- [10] LIU, Z., LIN, Y., CAO, Y., HU, H., WEI, Y., ZHANG, Z., LIN, S., GUO, B., Swin Transformer: Hierarchical vision transformer using shifted windows. *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 10012-10022, 2021. DOI: 10.1109/ICCV48922.2021.00986. URL: <https://arxiv.org/abs/2103.14030>
- [11] PASZKE, A., GROSS, S., MASSA, F. et al., PyTorch: An imperative style, high-performance deep learning library. *Advances in Neural Information Processing Systems*

- (NeurIPS), 32:8024-8035, 2019. URL: <https://papers.nips.cc/paper/9015-pytorch-an-imperative-style-high-performance-deep-learning-library>
- [12] WIGHTMAN, R., PyTorch Image Models (timm). GitHub repository, 2019-2025. URL: <https://github.com/huggingface/pytorch-image-models>
- [13] ONNX RUNTIME, ONNX Runtime: cross-platform, high performance ML inferencing and training accelerator. Microsoft, 2024. URL: <https://onnxruntime.ai/>
- [14] MCNEMAR, Q., Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, 12(2):153-157, 1947. DOI: 10.1007/BF02295996. URL: <https://link.springer.com/article/10.1007/BF02295996>
- [15] BONFERRONI, C. E., Teoria statistica delle classi e calcolo delle probabilità. Pubblicazioni del R Istituto Superiore di Scienze Economiche e Commerciali di Firenze, 8:3-62, 1936.
- [16] AMERICAN CANCER SOCIETY, Cancer Facts and Figures 2024. American Cancer Society, Atlanta, USA, 2024. URL: <https://www.cancer.org/research/cancer-facts-statistics/all-cancer-facts-figures/2024-cancer-facts-figures.html>
- [17] ARGENZIANO, G., SOYER, H. P., DE GIORGI, V. et al., Interactive Atlas of Dermoscopy. EDRA Medical Publishing & New Media, Milan, 2002. ISBN: 978-8886457309.
- [18] ANTHROPIC, Claude (Sonnet 4.6) — large language model assistant used for research, code and documentation support. Anthropic PBC, 2026. URL: <https://www.anthropic.com/claude>

EKLER

EK A. Tüm Hiperparametre Detayları

Bu ek, Bölüm 3.2'de özet olarak verilen hiperparametrelerin tam listesini içerir. Eğitim Ultralytics framework versiyonu 8.3.x ve timm 1.0.x ile gerçekleştirilmiştir.

Tablo A.1. Tüm hiperparametrelerin tam listesi

Parametre	Değer
YOLO data path	/content/cls_data
YOLO epochs	50
YOLO patience	15
YOLO batch	128
YOLO imgsz	384
YOLO optimizer	AdamW
YOLO lr0	0.001
YOLO lrf	0.01
YOLO weight_decay	0.0001
YOLO warmup_epochs	3.0
YOLO momentum	0.937
YOLO close_mosaic	10
YOLO cos_lr	True
YOLO deterministic	True
YOLO seed	0
YOLO amp	True
YOLO mosaic	1.0
YOLO mixup	0.1
YOLO erasing	0.4
YOLO degrees	30
YOLO flipud	0.5
YOLO fliplr	0.5
YOLO auto_augment	randaugment
timmm model 1	convnext_tiny.fb_in22k_ft_in1k_384
timmm model 2	swin_tiny_patch4_window7_224.ms_in22k_ft_in1k
timmm scheduler	OneCycleLR (cosine)
timmm label_smoothing	0.05
ONNX opset	14

ONNX FP16 fonksiyonu	onnxconverter_common.float16.convert_float_to_float16
ONNX keep_io_types	True

EK B. Android Uygulama Ekran Görüntüleri

Android uygulamanın altı ana ekranı (Onboarding, İzinler, Kamera, Görüntü Kalitesi, Sonuç, Tahmin Geçmişi) Jetpack Compose Material 3 tasarım dili kullanılarak geliştirilmiştir. Ekran görüntüleri savunma sunumunda gösterilecektir. Ekranların temel etkileşim akışı şu şekildedir: (i) Uygulama açılışında onboarding ekranında hastanın bilgilendirilmesi, (ii) Kamera ve depolama izinlerinin istenmesi, (iii) Kamera ekranında lezyona odaklanma ve fotoğraf çekme, (iv) Görüntü kalite kontrolünden geçirilmesi (blur/aydınlatma uyarıları), (v) ONNX modelinin çıkarımının arka planda çalıştırılması, (vi) Sonuç ekranında tahmin edilen sınıf ve güven değerinin gösterilmesi, (vii) Tahminin Room veritabanına kaydedilmesi.

EK C. Veri Seti Sınıf Dağılımı

Aşağıdaki tabloda yedi sınıfın eğitim, doğrulama ve test alt kümelerindeki örnek sayıları verilmiştir.

Tablo C.1. Birleşik veri setinin sınıf dağılımı

Sınıf	Eğitim	Doğrulama	Test
AKIEC	1,623	508	327
BCC	2,535	791	514
BKL	5,420	1,693	1,099
DF	564	176	115
MEL	2,196	686	445
NV	5,489	1,715	1,113
VASC	380	75	77
TOPLAM	18,207	5,644	3,690

ÖZGEÇMİŞ

Erkan AKTUNÇ, lise eğitimini takiben Sakarya Üniversitesi Bilgisayar ve Bilişim Bilimleri Fakültesi Bilişim Sistemleri Mühendisliği Bölümü'nü kazanmıştır. Lisans eğitimi sırasında özellikle bilgisayarlı görme, derin öğrenme ve mobil uygulama geliştirme alanlarına ilgi göstermiştir. Bu kapsamda Python (PyTorch, TensorFlow), Kotlin (Jetpack Compose), JavaScript (React Native), C++ ve Java dillerinde proje deneyimi edinmiştir.

2024-2026 dönemlerinde TÜBİTAK 2209-A Üniversite Öğrencileri Araştırma Projeleri Destek Programı kapsamında destek almış ve 'Yapay Zekâ Temelli Mobil Cilt Kanseri Tarama Sistemi' başlıklı projeyi yürütmüştür. Bu proje sürecinde Google Colab + Drive tabanlı eğitim akışları, ONNX model dönüşümleri, Android Jetpack Compose UI geliştirme, CameraX entegrasyonu ve istatistiksel anlamlılık testleri (McNemar, Bonferroni düzeltmesi) gibi konularda derinleşmiştir.

Akademik ilgi alanları arasında tıbbi görüntü analizi, multimodal derin öğrenme, mobil edge-AI deployment ve veri tabanlı sağlık teknolojileri yer almaktadır. Lisans sonrası akademik kariyerini Bilgisayar Bilimleri/Yapay Zekâ alanında yüksek lisans ile sürdürmeyi planlamaktadır.

İletişim: aktuncerkan04@gmail.com

ISE 401 BİLİŞİM SİSTEMLERİ MÜHENDİSLİĞİ TASARIMI
DEĞERLENDİRME VE SÖZLÜ SINAV TUTANAĞI

KONU: Yapay Zekâ Temelli Mobil Cilt Kanseri Tarama Sistemi: YOLO Tabanlı Çoklu Mimari Ensemble ile Dermoskopik Görüntü Sınıflandırması

ÖĞRENCİ (No / Ad / Soyad): Erkan AKTUNÇ

Değerlendirme Konusu	İstenenler	Not Aralığı	Not
Yazılı Çalışma — Çalışma kılavuza uygun olarak hazırlanmış mı?	x	0-5	
Teknik Yönden — Problemin tanımı yapılmış mı?	x	0-5	
Geliştirilecek yazılımın/donanımın mimarisini içeren blok şeması çizilerek açıklanmış mı?	x	—	
Blok şemadaki birimler arasındaki bilgi akışına ait model/gösterim var mı?	x	—	
Yazılımın gereksinim listesi oluşturulmuş mu?	x	—	
Kullanılan/ kullanılması düşünülen araçlar/teknolojiler anlatılmış mı?	x	—	
Donanımların programlanması/konfigürasyonu için yazılım gereksinimleri belirtilmiş mi?	x	—	
UML ile modelleme yapılmış mı?	x	—	
Veritabanları kullanılmış ise kavramsal model çıkarılmış mı?	x	—	

Projeye yönelik iş-zaman çizelgesi çıkarılarak maliyet analizi yapılmış mı?	x	—	
Donanım bileşenlerinin maliyet analizi (prototip-adetli seri üretim vb.) çıkarılmış mı?	—	—	
Donanım için gerekli enerji analizi (min-uyku-aktif-maks) yapılmış mı?	x	—	
Sürüm denetim sistemi (Git, Subversion vs.) kullanılmış mı?	x	—	
Sistemin genel testi için uygulanan metotlar ve iyileştirme süreçlerinin dökümü verilmiş mi?	x	—	
Performans testi yapılmış mı?	x	—	
Tasarımın uygulamasında ortaya çıkan uyumsuzluklar ve aksaklıklar belirtilerek çözüm yöntemleri tartışılmış mı?	x	—	
Yapılan işlerin zorluk derecesi?	x	0-25	
Sözlü Sınav — Yapılan sunum başarılı mı?	x	0-5	
Soruları yanıtlama yetkinliği?	x	0-20	
Devam Durumu — Öğrenci dönem içerisinde raporlarını düzenli olarak hazırladı mı?	x	0-5	
TOPLAM		100	

Danışman:

İmza:

Tarih: _____ / _____ / 2026